Prabhavit Gupta

AI Engineer | Agentic AI, LLM Orchestration, MCP Integrations, RAG & RAGAS

+39 351 610 7807 | prabhavitg@gmail.com | linkedin.com/in/prabhavit | github.com/prab-gupta | Venezia / Milano, Italia (Residente Permanente UE | Full Remote | Disponibilità Immediata)

Profilo Professionale / Career Summary

- **AI Engineer specializzato in Sistemi Agentici ed Architetture LLM End-to-End:** Progettazione ed implementazione di pipeline basate su Large Language Models (OpenAI, Anthropic, vLLM, Ollama), orchestrazione multi-agente (LangGraph, LangChain, LlamaIndex), intent classification, routing semantico e query rewriting/expansion in produzione.
- **Integrazione Avanzata Tool Calling, MCP e Sistemi RAG Ibridi:** Esperienza diretta nell'adozione del *Model Context Protocol (MCP)* per collegare agenti autonomi a database, API aziendali e servizi esterni; sviluppo di architetture RAG avanzate con hybrid search (BM25 + dense embedding), reranking semantico, Knowledge Graph (GraphRAG / Neo4j) e chunking dinamico per dati non strutturati.
- **Evaluation Frameworks, Sicurezza e Validazione RAGAS:** Implementazione sistematica di metriche di valutazione quantitativa (RAGAS: context precision/recall, answer relevancy, faithfulness) per eliminare allucinazioni; implementazione di NeMo Guardrails, regression test per prompt e pipeline AI scalabili ed orientate alla produzione business.

Competenze Tecniche / Technical Skills

- **LLM & Agent Orchestration:** Agentic AI Design Patterns, LangGraph, LangChain, LlamaIndex, Multi-Agent Systems, Autonomous Tool Calling, ReAct, Intent Classification, Query Routing & Expansion.
- **Protocolli & Integrazione Tool:** Model Context Protocol (MCP - Anthropic/Open Source), Custom MCP Server/Client Development, Function Calling, REST APIs, JSON Schema Enforcement, Structured Outputs (Pydantic).
- **RAG, Retrieval & Knowledge Graphs:** Retrieval-Augmented Generation (RAG), Hybrid Search (Dense + Sparse/BM25), Cross-Encoder Reranking, Vector DBs (Qdrant, Pinecone, Chroma, pgvector), GraphRAG, Neo4j, Entity & Relationship Extraction.
- **AI Models & Deployment:** OpenAI (GPT-4o), Anthropic Claude 3.5 Sonnet, open-source LLMs via vLLM, Ollama, Hugging Face Transformers, Token Optimization, Cost/Latency Tradeoff Analysis.
- **Evaluation & Sicurezza LLM:** RAGAS Framework, DeepEval, Prompt Regression Testing, Hallucination Detection, NeMo Guardrails, Input/Output Filtering, PII Masking, OWASP Top 10 for LLMs.
- **Linguaggi & Backend Engineering:** Python (FastAPI, AsyncIO, PyDantic, PyTest), TypeScript / Node.js, SQL (PostgreSQL), Docker, CI/CD, Git, Linux.

Esperienza Professionale / Work Experience

AI Engineer & Solutions Architect • *Indipendente / Consulenza AI Enterprise*
2024 – Presente • Venezia & Milano, IT

- Progettazione e rilascio di architetture agentiche end-to-end con orchestrazione complessa via LangGraph e protocollo MCP (Model Context Protocol), connettendo agenti decisionali ad ERP, database vettoriali ed API di terze parti.
- Costruzione di pipeline RAG ibride ad alte prestazioni su corpus documentali eterogenei: implementazione di chunking semantico, generazione embedding bilingue (italiano/inglese), hybrid retrieval (BM25 + vettoriale) e Cohere reranker, riducendo l'hallucination rate di oltre il 40%.
- Integrazione di Knowledge Graph ed approcci GraphRAG per mappare entità e relazioni complesse da documentazione non strutturata, migliorando l'accuratezza di retrieval per query contestuali multi-step.
- Implementazione di benchmark quantitativi continui con RAGAS (faithfulness, answer relevance, context precision), automatizzando regression test per prompt prima di ogni rilascio in esercizio.
- Configurazione di guardrails di sicurezza per il filtraggio di prompt injection, mascheramento PII e validazione dello schema JSON di output tramite Pydantic in scenari enterprise.

Full-Stack AI Software Engineer • *Tech Automation Systems*
2023 – 2024 • Milano / Remoto, IT

- Sviluppo di microservizi ad alto throughput in Python (FastAPI) e TypeScript dedicati all'elaborazione automatizzata di flussi informativi aziendali ed integrazione LLM.
- Ingegnerizzazione di pipeline di data ingestion per documenti non strutturati (PDF, contratti, schede tecniche) con parsing, normalizzazione, metadati arricchiti ed indicizzazione su vector store (Qdrant e pgvector).
- Ottimizzazione della latenza e dei costi inferenziali combinando modelli proprietari (OpenAI) con runtime locali open source (Ollama, vLLM) per task specifici di classificazione ed estrazione entità.
- Collaborazione diretta con stakeholder tecnici e di business per definire requisiti funzionali, prototipare rapidamente soluzioni AI e condurre sessioni di user acceptance testing.

Progetti Chiave / Key Projects

- **Enterprise Multi-Agent Ecosystem via MCP (Model Context Protocol):** Piattaforma open-source di agenti cooperativi orchestrati per eseguire task multi-step su filesystem, database e servizi web esterni, con tracciamento della memoria contestuale e validazione dello stato.
- **Production GraphRAG & Hybrid Retrieval Engine:** Motore RAG con estrazione automatizzata di nodi/archi su Neo4j combinato con hybrid search su Qdrant, validato tramite pipeline di test continuo RAGAS con punteggi medi di fedeltà superiore al 92%.

Formazione & Lingue / Education & Languages

- **Bachelor of Arts in Philosophy & Economics** – Università Ca' Foscari Venezia (2018 – 2022)
  Focus su logica formale, modelli decisionali, teoria dei giochi ed analisi quantitativa.
- **Lingue:** Italiano (fluente / operativo), Inglese (C1 professionale, eccellente padronanza scritta e orale).
- **Stato Legale & Fiscale:** Cittadino extra-UE con Permesso di Soggiorno UE per Soggiornanti di Lungo Periodo a Tempo Indeterminato (diritto al lavoro senza visto in Italia/UE); Partita IVA attiva / regime forfettario pronto.