# Prabhavit Gupta

AI Engineer | Architetture RAG Agentiche Multi-Turno, LlamaIndex, Gemini & Pgvector

+39 351 610 7807 | prabhavitg@gmail.com | linkedin.com/in/prabhavit | github.com/prab-gupta | Venezia / Milano, Italia (Residente Permanente UE | Presenza Flessibile Milano | Immediata)

## Profilo Professionale / Career Summary

- **Ingegneria di Sistemi AI & Architetture RAG Agentiche Multi-Turno:** Oltre 3 anni di esperienza nello sviluppo ed industrializzazione di applicazioni AI complesse. Specializzato nella progettazione di architetture RAG conversazionali multi-turno con orchestrazione agentica (LlamaIndex, LangGraph), gestione dello stato di sessione, query transformation dinamica, disambiguazione contestuale e verifica della fedeltà delle risposte.
- **Backend Engineering ad Alte Prestazioni con Python & FastAPI:** Comprovata esperienza nella costruzione di microservizi asincroni ad alta velocità in Python con FastAPI, pydantic per validazione rigorosa degli schemi JSON e integrazione nativa delle API di modelli di frontiera (Google Gemini 1.5 Pro / Flash, OpenAI, Anthropic Claude).
- **Archiviazione Vettoriale & Caching Scalabile con PostgreSQL, Pgvector e Redis:** Implementazione di pipeline di retrieval ibrido ad alte prestazioni su PostgreSQL (estensione pgvector per indicizzazione HNSW/IVFFlat), combinate con semantic search, reranking e livelli di caching in-memory su Redis per minimizzare la latenza inferenziale e i costi operativi.

## Competenze Tecniche / Technical Skills

- **Linguaggi & Framework di Sviluppo:** Python (Avanzato), FastAPI, AsyncIO, PyDantic, TypeScript, Node.js, SQL, Bash.
- **Agentic AI & LLM Frameworks:** LlamaIndex (Index Query Engines, Sub-Question Querying, Multi-Document Agents), LangGraph, LangChain, Tool Calling, Multi-Turn ReAct Patterns, Google Gemini API, OpenAI API, Anthropic Claude.
- **Database Vettoriali & Storage:** PostgreSQL, Pgvector (HNSW Indexing, cosine/L2 distance), Redis (Session State, Semantic Cache, Vector Memory), Qdrant, ChromaDB.
- **Strategie RAG Avanzate:** Hybrid Search (Sparse BM25 + Dense Embeddings), Cross-Encoder Reranking (Cohere, BGE), Chunking Semantico, Metadata Filtering, Context Compression, RAGAS Metrics.
- **DevOps & Messa in Produzione:** Docker, Docker Compose, Git, GitHub Actions CI/CD, Linux Server Management, Logging & Tracing strutturato, Protezione contro Prompt Injection.

## Esperienza Professionale / Work Experience

**AI Engineer & Solutions Architect** • *Indipendente / Consulenza AI Enterprise*
2024 – Presente • Venezia & Milano, IT

- Progettazione e implementazione di motori RAG agentici multi-turno end-to-end con LlamaIndex e LangGraph, consentendo agli utenti di interrogare basi di conoscenza complesse attraverso dialoghi continui con conservazione della memoria episodica.
- Integrazione di modelli multimodali e long-context di Google Gemini (Gemini 1.5 Pro e Gemini Flash) con prompt strutturati per l'estrazione ad alta precisione da documenti tecnici e contrattuali.
- Costruzione del layer di persistenza vettoriale su PostgreSQL con estensione Pgvector, ottimizzando query HNSW per dataset ad elevata dimensionalità e riducendo il tempo di latenza medio a meno di 45ms.
- Implementazione di un layer di semantic caching basato su Redis per memorizzare e riutilizzare risposte ed embedding di query frequenti, abbattendo i costi di chiamata API del 38%.
- Sviluppo di API RESTful robuste e documentate con FastAPI e Pydantic, garantendo tipi rigidi, streaming token (SSE) ed autenticazione sicura per l'integrazione con frontend aziendali.
- Creazione di test automatici di regressione per prompt e verifica della precisione semantica con benchmark RAGAS per impedire allucinazioni.

**Full-Stack AI Software Engineer** • *Tech Automation Systems*
2023 – 2024 • Milano / Remoto, IT

- Sviluppo di microservizi backend in Python (FastAPI) e pipeline asincrone per l'automazione dei processi documentali e l'analisi automatizzata di flussi informativi.
- Progettazione di database relazionali su PostgreSQL e gestione di code di messaggi asincrone con Redis per carichi di lavoro batch e data ingestion distribuiti.
- Integrazione di modelli linguistici di grandi dimensioni per la classificazione automatica delle richieste, categorizzazione degli intenti ed estrazione strutturata di entità.
- Collaborazione attiva in team multidisciplinari (sviluppatori, architetti, PM) adottando metodologie Agile/Scrum, revisione del codice e pratiche di continuous integration.

## Progetti di Rilievo / Notable Projects

- **Motore RAG Conversazionale Multi-Turno (LlamaIndex + Pgvector):** Piattaforma di knowledge retrieval che combina interrogazione gerarchica dei documenti via LlamaIndex, storage vettoriale HNSW su Pgvector e memoria contestuale multi-sessione salvata in Redis.
- **High-Throughput Agentic Gateway (FastAPI + Google Gemini):** Gateway API per l'orchestrazione di agenti con function calling nativo, streaming asincrono in real-time e caching semantico, validato per oltre 100 richieste concorrenti con latenza sub-secondo.

## Formazione & Lingue / Education & Languages

- **Bachelor of Arts in Philosophy & Economics** – Università Ca' Foscari Venezia (2018 – 2022)
  *Formazione avanzata in logica matematica, modelli decisionali, teoria dei giochi ed analisi dei sistemi.*
- **Lingue:** Inglese (C1 Professionale / Fluente), Italiano (Lavorativo / Fluente nei contesti professionali).
- **Stato di Residenza e Fiscale:** Cittadino extra-UE con Permesso di Soggiorno UE a Tempo Indeterminato (pieni diritti di lavoro in Italia/UE senza necessità di sponsorizzazione); Partita IVA attiva / regime ordinario o forfettario pronto.