Prabhavit Gupta

Senior Generative AI Engineer | Agentic AI, LangGraph, Model Context Protocol (MCP) & RAG

+39 351 610 7807 | prabhavitg@gmail.com | linkedin.com/in/prabhavit | github.com/prab-gupta | Venezia / Torino, Italia (Residente Permanente UE | Presenza Ibrida | Immediata)

Profilo Professionale / Career Summary

- **Generative AI & Sistemi Multi-Agente Enterprise:** 3 anni di esperienza professionale nell'ingegneria del software e nello sviluppo di soluzioni AI enterprise end-to-end. Specializzato nell'orchestrazione di Large Language Models commerciali ed open-source (OpenAI GPT-4o, Anthropic Claude 3.5, Google Gemini) tramite framework moderni quali LangGraph, LangChain e LlamaIndex, realizzando workflow agentici con state machines, retry policy e fallback automatici.
- **Model Context Protocol (MCP) & Integrazione Tool:** Pioniere nell'implementazione dello standard Model Context Protocol (MCP Server e MCP Client), progettando interfacce sicure e tipizzate che consentono ad agenti AI di eseguire query documentali, interrogazioni SQL e chiamate a servizi REST esterni tramite function calling e output strutturati (Pydantic).
- **Pipeline RAG Avanzate, Valutazione & MLOps:** Progettazione di pipeline di Retrieval-Augmented Generation (RAG) ad alte prestazioni con PostgreSQL pgvector e Qdrant (chunking semantico, hybrid search BM25, reranking). Adozione di metodologie di valutazione continua (framework RAGAS, guardrail contro prompt injection) e deployment di microservizi containerizzati con Docker, FastAPI e pipeline CI/CD.

Competenze Tecniche / Technical Skills

- **Agentic AI & Orchestrazione LLM:** LangGraph, LangChain, LlamaIndex, Semantic Kernel, Sistemi Multi-Agente, ReAct Planning, Tool/Function Calling, Structured Outputs (Pydantic / JSON Schema), Gestione dello Stato e Memoria Contestuale.
- **Model Context Protocol (MCP):** MCP Server & Client Development, Connettori di Dati, Tool Execution Standardizzata, Prompt Injection Guardrails, Controllo Accessi (RBAC).
- **RAG, Vector Search & Basi Dati:** Retrieval-Augmented Generation (Agentic RAG), Ingestion Documentale, PostgreSQL pgvector, Qdrant, ChromaDB, Hybrid Search (Dense + Sparse BM25), Cohere Reranking, Caching Semantico.
- **Modelli Generativi & Cloud Services:** OpenAI (GPT-4o, o1), Azure OpenAI Service, Anthropic Claude, Google Gemini, AWS (Bedrock, S3, Lambda), Docker, Git, GitHub Actions CI/CD.
- **Backend Engineering & API:** Python (Avanzato - FastAPI, AsyncIO, PyTest, Type Hints), TypeScript, Node.js, SQL, RESTful APIs, Webhook, Logging Strutturato e Distributed Tracing.
- **Valutazione & AI Quality:** RAGAS Framework, Precision/Recall, LLM-as-a-Judge, Prompt Regression Testing, Minimizzazione Allucinazioni, Ottimizzazione di Costi e Latenza.

Esperienza Professionale / Work Experience

Senior AI Engineer & Consulente Generative AI • *Attività Indipendente / Consulenza AI Enterprise*
2024 – Presente • Venezia & Torino / Remoto, IT

- Progettazione e implementazione di architetture agentiche complesse per clienti enterprise utilizzando LangGraph e Python, orchestrando team di agenti specializzati con transizioni di stato deterministiche e validazione human-in-the-loop.
- Sviluppo di connettori personalizzati basati su Model Context Protocol (MCP), consentendo agli agenti LLM di accedere in modo trasparente e verificabile a database relazionali PostgreSQL e document repository proprietari.
- Realizzazione di pipeline RAG ibride ad alte prestazioni su vector store PostgreSQL pgvector e Qdrant, riducendo la latenza di risposta sotto il secondo e azzerando le allucinazioni su documentazione tecnica complessa.
- Creazione di test suite di regressione e benchmark qualitativi tramite il framework RAGAS per valutare fedeltà contestuale, rilevanza e robustezza su versioni successive dei modelli.
- Containerizzazione delle soluzioni tramite Docker e rilascio continuo con pipeline CI/CD, integrando monitoraggio dei consumi di token e tracing distribuito OpenTelemetry.

Full-Stack AI Software Engineer • *Tech Automation Systems*
2023 – 2024 • Milano / Remoto, IT

- Sviluppo di microservizi asincroni in Python (FastAPI) e TypeScript per il parsing, la classificazione automatica e l'estrazione di metadati strutturati da volumi elevati di documenti PDF.
- Integrazione di indici vettoriali e code di ingestion asincrone con Redis e database PostgreSQL, garantendo throughput elevato e continuità del servizio.
- Scrittura di unit test e test di integrazione completi con PyTest, assicurando affidabilità del codice e conformità alle specifiche di rilascio.
- Collaborazione attiva con stakeholder di business per definire i requisiti funzionali dei moduli AI e documentare le

architetture software.

Progetti di Rilievo / Key Projects

- **Piattaforma Multi-Agente con Integrazione MCP (Python + LangGraph):** Sistema collaborativo ad agenti per il triage, il recupero informativo e la sintesi di report operativi con esecuzione di tool certificati via Model Context Protocol.
- **Motore RAG Enterprise di Ricerca Semantica (Python + pgvector):** Motore di indicizzazione e retrieval per documenti aziendali con dense embeddings, BM25 keyword search, semantic caching e guardrail di sicurezza contro injection.

Formazione, Lingue & Permessi di Lavoro

- **Laurea Triennale in Filosofia ed Economia** – Università Ca' Foscari di Venezia (2018 – 2022)
  Formazione rigorosa in logica formale, teoria delle decisioni, analisi quantitativa e modellazione di sistemi complessi.
- **Competenze Linguistiche:** Inglese (C1 Professionale, fluente parlato e scritto), Italiano (Livello lavorativo).
- **Stato Giuridico & Disponibilità:** Residente Permanente UE in Italia (Permesso di Soggiorno UE a Tempo Indeterminato) – Diritto di lavoro immediato senza necessità di visto o sponsorizzazione; disponibilità immediata a modalità ibrida.