Prabhavit Gupta

Arquitecto de IA / Senior AI Engineer | LLMs, Agentic AI, Model Context Protocol (MCP) & RAG

+39 351 610 7807 | prabhavitg@gmail.com | linkedin.com/in/prabhavit | github.com/prab-gupta | Venecia, Italia / España (Residente Permanente UE | Disponibilidad Inmediata | Modalidad Híbrida/Remota)

Perfil Profesional / Summary

- **Arquitectura de IA Generativa & Sistemas Agenticos en Producción:** Ingeniero de software con 3 años de experiencia comercial en el diseño y despliegue de soluciones de inteligencia artificial en producción. Especializado en arquitecturas basadas en Large Language Models (modelos open-source y frontier models), agentes autónomos, voicebots/chatbots y automatizaciones inteligentes de procesos.
- **Model Context Protocol (MCP) & Integración de Herramientas:** Experiencia avanzada desarrollando servidores y clientes basados en el estándar Model Context Protocol (MCP), permitiendo a agentes inteligentes consultar bases de datos relacionales, repositorios documentales y APIs REST externas mediante tool calling y esquemas tipificados (Pydantic).
- **Pipelines RAG Avanzados, Serving de Modelos & Evaluación:** Especialista en Retrieval-Augmented Generation (RAG) de alta velocidad con PostgreSQL pgvector y Qdrant (chunking semántico, búsqueda híbrida, reranking). Experiencia en serving de inferencia (vLLM, quantización, optimización de latencia y throughput) y suites de evaluación automatizada (RAGAS framework).

Competencias Técnicas / Technical Skills

- **IA Generativa & LLMs:** Modelos Open-Source (Llama, Mistral), OpenAI GPT-4o, Anthropic Claude, Prompt Engineering Avanzado, Function/Tool Calling, Structured Outputs (Pydantic / JSON Schema), Guardrails de Seguridad.
- **Model Context Protocol (MCP) & Agentes:** MCP Server & Client Development, Conectores de Datos Seguros, LangGraph, LangChain, LlamaIndex, Arquitecturas Multi-Agente, Planificación ReAct, Estado y Memoria.
- **Inferencia & Optimización:** vLLM, Serving de Inferencia, Cuantización de Modelos, Optimización de GPU, Benchmarking de Latencia, Rendimiento y Consumo de Recursos.
- **RAG, Vector Search & Bases de Datos:** Retrieval-Augmented Generation (RAG), Ingesta de Documentos, PostgreSQL pgvector, Qdrant, ChromaDB, Búsqueda Híbrida (Dense + Sparse BM25), Caching Semántico (Redis).
- **Ingeniería de Software & DevOps:** Python (FastAPI, AsyncIO, PyTest, Type Hints), TypeScript, Node.js, Docker, Kubernetes/k3s, Git, GitHub Actions CI/CD, Arquitectura de Microservicios.
- **Evaluación & Observabilidad:** Framework RAGAS, Precisión/Recall/Fidelidad, OpenTelemetry Tracing, Logging Estructurado, Control de Costes y Presupuesto de Tokens.

Experiencia Profesional / Work Experience

Arquitecto de Soluciones de IA & Consultor Senior • *Consultoría Independiente de Ingeniería de IA*
2024 – Presente • Venecia, IT (Remoto Europa / España)

- Diseñé e implementé arquitecturas complejas de agentes autónomos y pipelines de IA generativa para empresas europeas, traduciendo requisitos operativos en soluciones robustas y escalables.
- Desarrollé conectores certificados bajo el protocolo Model Context Protocol (MCP), dotando a agentes LLM de acceso auditable y seguro a bases de datos relacionales y servicios SaaS internos.
- Construí motores RAG híbridos de alto rendimiento sobre PostgreSQL pgvector y Qdrant, alcanzando tiempos de respuesta sub-segundo con cero alucinaciones sobre documentación técnica.
- Implementé bancos de pruebas y evaluación continua con el framework RAGAS, midiendo fidelidad contextual y relevancia de respuestas ante actualizaciones de modelos e inferencia.
- Empaqueté microservicios de IA en contenedores Docker y configuré flujos de integración y despliegue continuo (CI/CD) con observabilidad y tracing distribuido.

Full-Stack AI Software Engineer • *Tech Automation Systems*
2023 – 2024 • Milán / Remoto, IT

- Desarrollé microservicios asíncronos en Python y TypeScript para el procesamiento, clasificación y extracción estructurada de datos a partir de grandes volúmenes de documentos PDF.
- Implementé flujos de indexación vectorial y colas de ingestión en segundo plano con Redis y PostgreSQL, garantizando alta disponibilidad y consistencia de datos.
- Creé suites de pruebas unitarias e integración con PyTest, manteniendo altos estándares de cobertura y calidad técnica en cada entrega.
- Colaboré activamente con responsables de producto y arquitectos técnicos en la definición de especificaciones de sistemas inteligentes.

Proyectos Destacados / Key Projects

- **Plataforma Multi-Agente con Servicios MCP (Python + LangGraph):** Sistema colaborativo de agentes para clasificación, extracción y redacción de informes con ejecución de herramientas verificadas vía Model Context Protocol.
- **Motor de Recuperación Documental Empresarial (Python + pgvector):** Motor RAG en producción combinando búsqueda semántica vectorial, búsqueda por palabras clave BM25 y guardrails contra inyecciones de prompt.

Formación, Idiomas & Estado Legal

- **Grado en Filosofía y Economía** – Universidad Ca' Foscari de Venecia (2018 – 2022)
  Formación analítica rigurosa en lógica formal, teoría de decisiones y modelado de sistemas complejos.
- **Idiomas:** Inglés (C1 Profesional, fluido hablado y escrito), Italiano (Competencia profesional), Español (Comprensión y lectura técnica).
- **Autorización Legal de Trabajo:** Residente Permanente de la Unión Europea (Permesso di Soggiorno UE a Tempo Indeterminato, Italia) – Pleno derecho legal a trabajar en España y en toda la UE sin necesidad de visado o patrocinio.