Prabhavit Gupta

Senior AI Engineer | Sistemas Multiagente, LLMs Multimodales, RAG & AWS

+39 351 610 7807 | prabhavitg@gmail.com | linkedin.com/in/prabhavit | github.com/prab-gupta | España / Venecia (Residencia Permanente UE | Permiso Ilimitado en España | 100% Remoto)

Summary

Senior AI Engineer con 3 años de experiencia comercial en el diseño, desarrollo e industrialización de soluciones avanzadas de Inteligencia Artificial Generativa, sistemas multiagente y modelos fundacionales (OpenAI, Gemini, Claude, Llama). Especializado en la implementación de arquitecturas agénticas en producción sobre AWS, flujos RAG con búsqueda semántica vectorial, optimización de prompts, evaluación continua (evals) y despliegue de microservicios contenerizados (Docker, Kubernetes) bajo pipelines automatizados de CI/CD. Residente permanente en la Unión Europea con autorización laboral ilimitada en España, inmediatamente disponible para posiciones 100% remotas.

Experience

FlowSpace.co • *Lead AI Engineer & Multi-Agent Systems Architect (Freelance)*
Mar 2024 - Aug 2026 • Londres, UK (remoto)

- Diseñó y desplegó en producción arquitecturas agénticas y sistemas multiagente (LangGraph) para más de 4.500 usuarios empresariales activos, integrando modelos de Claude, OpenAI y Llama.
- Implementó pipelines RAG avanzados sobre bases de conocimiento corporativas combinando búsqueda híbrida semántica, vector store (pgvector, Chroma) y algoritmos de re-ranking.
- Desarrolló suites automatizadas de evaluación y optimización de modelos (evals, LangSmith) para medir precisión fáctica, mitigar alucinaciones y reducir costes de inferencia en un 35%.
- Expuso capacidades de IA mediante APIs REST de alto rendimiento y microservicios asíncronos en FastAPI con rigurosa seguridad, validación de esquemas y monitorización de latencias (<1.8s).
- Empaquetó y orquestó aplicaciones mediante contenedores Docker y clústeres Kubernetes sobre infraestructura cloud de AWS, integrando pipelines de CI/CD para despliegues continuos.
- *Tecnologías: Python, LLMs, Multi-Agent Systems, LangGraph, RAG, AWS, Docker, Kubernetes, FastAPI, CI/CD, Git*

Urlink • *AI Software Engineer (Freelance)*
Apr 2025 - Jul 2025 • Barcelona, España (remoto)

- Desarrolló servicios de ingesta, normalización y extracción semántica de información a partir de flujos de datos no estructurados para clientes internacionales.
- Construyó servicios backend en FastAPI e integró modelos de lenguaje para clasificaciones y transformaciones de texto en tiempo real.
- Diseñó pruebas automatizadas y contenedores Docker para garantizar la portabilidad y robustez de los despliegues en staging y producción.
- *Tecnologías: Python, FastAPI, Pydantic, PostgreSQL, Docker, REST APIs, Git*

Consultor Técnico Independiente • *AI Solutions Engineer*
Sep 2023 - Mar 2024 • Venecia, Italia

- Diseñó e integró soluciones de IA generativa, asistentes virtuales corporativos y flujos RAG para empresas europeas en sectores logísticos y de servicios.
- Asesoró a clientes en la selección de modelos LLM, ingeniería de prompts, seguridad de datos corporativos y mitigación de sesgos.
- Redactó especificaciones técnicas de integración, esquemas OpenAPI y guías operativas de mantenimiento y supervisión de modelos.
- *Tecnologías: Python, LangChain, OpenAI APIs, Vector DB, FastAPI, Linux, Git*

Tractionboard.co • *Full-Stack Automation Developer (Prácticas)*
Aug 2023 - Oct 2023 • Utrecht, Países Bajos (remoto)

- Desarrolló flujos automatizados de sincronización de datos y webhooks para plataformas SaaS de analítica.
- *Tecnologías: Python, JavaScript, REST APIs, Git*

Education

Universidad Ca' Foscari de Venecia • *Grado en Filosofía, Estudios Internacionales y Economía (Minor en Emprendimiento)*
Oct 2020 - Jun 2024 • Venecia, Italia

Certifications

Microsoft: Introduction to building AI agents • Microsoft Copilot Studio Agent Academy • Microsoft Power Automate • Tray.AI Build Practitioner (Sep 2024) • Tray.AI Build Foundations

Additional Information

- **Autorización de Trabajo:** Residente Permanente de la UE con plena autorización laboral en España (sin necesidad de patrocinio de visado).
- **Idiomas:** Inglés (C1 profesional fluido), Español (intermedio comunicativo), Italiano (profesional), Hindi (nativo).
- **Disponibilidad:** Inmediata (0 días de preaviso) para dedicación full-time 100% remota.

Core Skills

- **Modelos & Sistemas Agénticos:** LLMs Multimodales (OpenAI, Gemini, Claude, Llama), Sistemas Multiagente, LangGraph, Prompt Engineering, Evals.
- **RAG & Búsqueda Semántica:** Retrieval Augmented Generation, Chunking, Embeddings, Bases de Conocimiento Corporativas, pgvector, Chroma, Re-ranking.
- **Desarrollo Backend & APIs:** Python 3.12, FastAPI, Programación Asíncrona, Pydantic, Microservicios, APIs REST seguras.
- **Cloud & DevOps:** AWS, Docker, Kubernetes, CI/CD, Observabilidad, Monitorización de Modelos, Git, Linux.