Prabhavit Gupta

AI Engineer | Production AI Systems, Agent Architectures, Retrieval & Financial Evals

+39 351 610 7807 | prabhavitg@gmail.com | linkedin.com/in/prabhavit | github.com/prab-gupta | Venezia, Italia (Residente in Italia | Permesso di Soggiorno UE a Tempo Indeterminato | Full Remote)

Profilo Professionale

- **Sviluppo di Sistemi AI in Produzione:** Software engineer con 3 anni di esperienza commerciale nello sviluppo e rilascio in produzione di sistemi basati su LLM, architetture agentiche e pipeline di retrieval per flussi di dati finanziari e aziendali. Forte focus su affidabilità deterministica, automazione end-to-end e codice pronto per la produzione (FastAPI, Docker, CI/CD, no prototipi usa-e-getta).
- **Knowledge Management, Re-ranking e Tool Use:** Ampia esperienza nella progettazione di sistemi di semantic search, vector databases (pgvector), re-ranking cross-encoder e integrazione di tool sicuri tramite Model Context Protocol (MCP Server & Client). Specializzato nell'interrogazione strutturata di dati transazionali, fatture e contabilità.
- **Framework di Valutazione Rigorosi (Evals):** Padroneggia la definizione e il monitoraggio di test suite di valutazione offline e online (RAGAS, test di regressione automatizzati, Langfuse tracing), quantificando sistematicamente accuratezza, aderenza ai fatti, latenza d'inferenza e costi computazionali prima di ogni deploy.

Competenze Tecniche

- **AI & LLM Engineering:** Production LLM Systems, Agentic Workflows, Tool Calling, Knowledge Retrieval & Memory, Semantic Search & Re-ranking, LangGraph, Prompt Engineering, Structured Outputs (Pydantic).
- **Data & Protocols:** Model Context Protocol (MCP Server & Client SDKs), PostgreSQL (pgvector), Redis (Caching), Data Pipelines, Document Parsing, Financial Transaction Classification.
- **Evals & Observability:** Eval-Driven Development, RAGAS Benchmarking, Regression Testing, Langfuse Distributed Tracing, Latency & Token Cost Profiling, Continuous Monitoring.
- **Software Engineering:** Python moderno (AsyncIO, FastAPI, PyTest, Typing), TypeScript, Elixir basics, Docker, Microservices, REST & WebSocket APIs, Git, GitHub Actions CI/CD.
- **Metodologie:** High Ownership, Architettura Difensiva, Code Reviews, ADRs, Collaborazione con Product, Data ed Engineering teams.

Esperienza Professionale

AI Engineer & Consulente Tecnico • *Consulenza Indipendente di Ingegneria AI*
2024 – Presente • Venezia, IT (Remoto)

- Progettato e rilasciato in produzione sistemi AI agentici e motori di retrieval aumentato per applicazioni enterprise europee, curando l'intero ciclo di vita dall'analisi dei requisiti al deploy.
- Implementato pipeline avanzate di retrieval, context management e re-ranking su banche dati relazionali e vettoriali, migliorando la precisione di estrazione e riconciliazione su documenti amministrativi e transazioni.
- Sviluppato server e client custom conformi al Model Context Protocol (MCP), consentendo ad agenti autonomi di eseguire tool use sicuro su database PostgreSQL con controllo rigoroso dei permessi e audit trail.
- Istituito framework sistematici di evaluation (evals) con dataset di test dedicati e benchmark RAGAS per validare metriche di completezza, precisione e controllo delle allucinazioni prima del rilascio.
- Integrato tracciamento distribuito (Langfuse, OpenTelemetry) per monitorare latenze p95/p99, consumi di token e comportamenti anomali su pipeline in produzione.
- Containerizzato microservizi in Docker e automatizzato i flussi di continuous integration e testing regressionale via GitHub Actions.

Full-Stack AI Software Engineer • *Tech Automation Systems*
2023 – 2024 • Milano / Remoto, IT

- Sviluppato servizi backend asincroni in Python e TypeScript per l'estrazione, la normalizzazione e la classificazione automatica di elevati volumi di dati aziendali.
- Implementato pipeline di ricerca semantica con PostgreSQL e Redis, garantendo tempi di risposta inferiori al secondo e caching efficiente degli embeddings.
- Scritto suite di test esaustive con PyTest e introdotto verifiche automatizzate di qualità del codice nei processi di integrazione continua.
- Collaborato attivamente con product manager, designer e stakeholder di business per tradurre requisiti operativi in soluzioni software robuste e modulari.

Progetti Rilevanti

- **Autonomous Tool-Using Agent Platform (Python + LangGraph + MCP + Postgres):** Piattaforma agentica multi-fase coordinata con gestione dello stato, memoria condivisa, integrazione tool via MCP e tracciamento

distribuito Langfuse.

- **Motore di Analisi Dati e Documenti Finanziari (FastAPI + pgvector):** Microservizio di retrieval semantico e parsing strutturato con convalida Pydantic, algoritmi di re-ranking e harness di valutazione per eliminare le regressioni.

Formazione, Lingue e Stato Legale

- **Laurea Triennale in Economia e Filosofia (Philosophy & Economics)** – Università Ca' Foscari di Venezia (2018 – 2022)
  Solida formazione quantitativa e teorica in logica formale, modelli decisionali, statistica e analisi dei sistemi economici complessi.
- **Lingue:** Italiano (Fluente / Professionale), Inglese (C1 Avanzato / Full Professional).
- **Stato Legale:** Permesso di Soggiorno UE per Soggiornanti di Lungo Periodo a Tempo Indeterminato (Italia) – Pieno diritto di lavoro e residenza permanente in Italia senza necessità di visto o sponsorizzazione; disponibile immediatamente.