Prabhavit Gupta

AI Engineer & Generative AI Engineer | LLM, RAG, Vector DB, MLOps & Python

+39 351 610 7807 | prabhavitg@gmail.com | linkedin.com/in/prabhavit | github.com/prab-gupta | Venezia, Italia (Residente Permanente UE | Disponibilità Immediata)

Summary

AI Engineer e Generative AI Engineer con 3 anni di esperienza commerciale nello sviluppo, testing e industrializzazione di soluzioni end-to-end basate su intelligenza artificiale, Large Language Models (LLM) e Machine Learning. Esperto nella progettazione di architetture RAG (Retrieval-Augmented Generation) avanzate con Vector Database (Qdrant, Pinecone, pgvector), tecniche di Prompt Engineering e generazione di dati sintetici (Synthetic Data Generation) per benchmark e validazione affidabile dei sistemi AI. Comprovata esperienza nella collaborazione con team di Data e Platform Engineering per il deployment in produzione di microservizi containerizzati (Docker, Kubernetes) su cloud AWS/Azure/GCP e nell'implementazione di pratiche MLOps. Residente permanente a Venezia, con ottimo inglese professionale (C1) e italiano lavorativo.

Experience

FlowSpace.co • *Lead AI Engineer & GenAI Architect (Freelance)*
Mar 2024 - Aug 2026 • Londra, UK (remoto)

- Progettato e rilasciato in produzione architetture generative e pipeline RAG per oltre 4.500 utenti enterprise attivi, integrando LLM commerciali e open-source con Vector Database (Qdrant, pgvector).
- Implementato tecniche avanzate di Prompt Engineering, structured outputs e catene di reasoning per eliminare allucinazioni e garantire latenze <1.8s in ambienti di produzione ad alto volume.
- Sviluppato pipeline di Synthetic Data Generation per generare dataset di test e valutare oggettivamente le metriche di retrieval (hit rate, MRR) e generazione (faithfulness, answer relevance).
- Coordinato con i team Data Engineering e Platform Engineering l'orchestrazione di microservizi FastAPI su Docker e AWS/GCP, integrando flussi di CI/CD e monitoraggio MLOps.
- Collaborato con stakeholder tecnici e di business per tradurre requisiti di dominio in specifiche architetturali e linee guida di governance AI.
- *Tecnologie: Python, Generative AI, PyTorch, RAG, Qdrant, Pinecone, FastAPI, Docker, AWS, Databricks, MLOps, Git*

Urlink • *AI & Machine Learning Engineer (Freelance)*
Apr 2025 - Jul 2025 • Barcellona, Spagna (remoto)

- Sviluppato modelli e pipeline per l'estrazione semantica, classificazione automatica e normalizzazione di dati testuali non strutturati.
- Realizzato pipeline di test automatizzati con dati sintetici per verificare la robustezza dei modelli contro edge cases ed errori di ingestion.
- Progettato API REST e microservizi per servire inferenze ML in tempo reale con validazione rigorosa degli schemi tramite Pydantic.
- *Tecnologie: Python, Scikit-learn, PyTorch, Pandas, PostgreSQL, Docker, REST APIs, Git*

Consulente Tecnico Indipendente • *AI Solutions Engineer*
Sep 2023 - Mar 2024 • Venezia, Italia

- Progettato e sviluppato soluzioni personalizzate di Generative AI, agenti conversazionali e workflow RAG per PMI europee.
- Guidato le fasi di prototipazione rapida, testing su benchmark dedicati e deployment su infrastrutture cloud sicure.
- Redatto documentazione tecnica completa, linee guida di prompt engineering e procedure operative per il monitoraggio dei modelli.
- *Tecnologie: Python, OpenAI API, LangChain, LlamaIndex, Vector DB, FastAPI, Linux, Git*

Tractionboard.co • *Full-Stack Automation Developer (Stage)*
Aug 2023 - Oct 2023 • Utrecht, Paesi Bassi (remoto)

- Sviluppato connettori webhook e pipeline di ingestion dati per piattaforme SaaS di analytics.
- *Tecnologie: Python, JavaScript, REST APIs, Git*

Education

Università Ca' Foscari di Venezia • *Laurea Triennale in Filosofia, Studi Internazionali ed Economia, Minor in Imprenditorialità*
Ott 2020 - Giu 2024 • Venezia, Italia

Certifications

Microsoft: Introduction to building AI agents • Microsoft Copilot Studio Agent Academy • Microsoft Power Automate • Tray.AI Build Practitioner (Sep 2024) • Tray.AI Build Foundations

Additional Information

- **Inquadramento:** Residente permanente UE a Venezia, Italia. Disponibile per contratti CCNL o collaborazione con Partita IVA.
- **Lingue:** Italiano (lavorativo), Inglese (fluente C1 professionale), Hindi (madrelingua).
- **Disponibilità:** Immediata (0 giorni di preavviso) per posizioni full-time remote / ibride.

Core Skills

- **Generative AI** & **LLM:** Large Language Models, Prompt Engineering, Synthetic Data Generation, Structured Outputs, Evals.
- **RAG** & **Vector Databases:** Retrieval-Augmented Generation, Qdrant, Pinecone, pgvector, Chunking Semantico, Hybrid Search.
- **Machine Learning** & **Linguaggi:** Python 3.12, PyTorch, Scikit-learn, TensorFlow, Databricks, FastAPI, Pydantic, SQL.
- **MLOps, Cloud** & **Architetture:** Docker, Kubernetes, AWS, Microsoft Azure, Google Cloud Platform, Microservizi, CI/CD, Git.
- **Metodologie:** Agile/Scrum, Collaboration Cross-funzionale, Redazione Architetturale, Problem Solving Analitico.